

**ĐẠI HỌC BÁCH KHOA HÀ NỘI**

**BÁO CÁO GIỮA KỲ DỰ ÁN**

**Môn học: Nhập môn Trí tuệ nhân tạo IT3160**

**XÂY DỰNG CHATBOT TRÍ TUỆ NHÂN TẠO  
TRUY VẤN DỮ LIỆU BÓNG ĐÁ CHÂU ÂU**

Sinh viên thực hiện: Nhóm 37

Phạm Thành Trung – 20235853

Lê Tuấn Trung – 20235852

Nguyễn Bá Tú – 20235857

**Hà Nội, 05-2026**

# 1. GIỚI THIỆU ĐỀ TÀI

Trong kỷ nguyên số, dữ liệu về các giải đấu bóng đá hàng đầu châu Âu (Premier League, La Liga, Serie A, Bundesliga, Ligue 1) được sinh ra với khối lượng khổng lồ sau mỗi vòng đấu. Tuy nhiên, việc tra cứu thủ công các thông số như kết quả trận đấu, tỷ số, hay đội chiến thắng trên các trang web thống kê truyền thống thường mất thời gian và thiếu tính tương tác.

Để giải quyết vấn đề này, bài toán xây dựng trợ lý ảo (Chatbot) có khả năng hiểu ngôn ngữ tự nhiên và trả lời các câu hỏi về bóng đá trở thành một hướng đi mang tính ứng dụng cao. Trong đề án này, em tiến hành xây dựng một hệ thống Information Retrieval (IR) Chatbot. Hệ thống sử dụng các thuật toán Học máy (Machine Learning) truyền thống và Xử lý ngôn ngữ tự nhiên (NLP) để chuyển đổi kho dữ liệu thống kê thô thành các câu trả lời chính xác, phục vụ nhu cầu tra cứu nhanh chóng của người hâm mộ.

## 2. MỤC TIÊU NGHIÊN CỨU

Đề tài hướng đến các mục tiêu chính trong giai đoạn giữa kỳ như sau:

- **Xây dựng pipeline dữ liệu:** Tự động hóa quá trình chuyển đổi dữ liệu dạng bảng (CSV) của các trận đấu thành tập dữ liệu huấn luyện dạng Hỏi - Đáp (Q&A).
- **Áp dụng Xử lý ngôn ngữ tự nhiên:** Tích hợp các kỹ thuật tiền xử lý văn bản tiếng Việt và biểu diễn ngôn ngữ dưới dạng vector (TF-IDF).
- **Huấn luyện mô hình:** Triển khai kết hợp thuật toán Naive Bayes (phân loại chủ đề) và K-Nearest Neighbors - KNN (tìm kiếm câu hỏi tương đồng).
- **Xây dựng giao diện người dùng (UI):** Thiết kế giao diện web trực quan, mang phong cách thể thao (Football Premium UI) để người dùng dễ dàng tương tác.

## 3. TỔNG QUAN BÀI TOÁN

### 3.1 Khái niệm

Trong hệ thống này, bài toán được định nghĩa là tìm kiếm câu trả lời phù hợp nhất từ một cơ sở dữ liệu tri thức có sẵn dựa trên truy vấn của người dùng. Khác với các mô hình tạo văn bản (Generative AI), hệ thống IR đảm bảo tính chính xác tuyệt đối về mặt số liệu (tỷ số, kết quả) do không bị hiện tượng "ảo giác" (hallucination).

### 3.2 Vai trò của NLP

NLP giúp máy tính hiểu được ý định truy vấn của người dùng dù họ sử dụng các cách diễn đạt khác nhau. Các kỹ thuật được sử dụng bao gồm: Tokenization (tách từ), Stopword Removal (loại bỏ từ nhiễu), và TF-IDF Vectorization.

### 3.3 Những khó khăn

- ❑ **Sự đa dạng trong truy vấn:** Người dùng có thể hỏi "Kết quả trận MU vs Arsenal" hoặc "Ai thắng trận MU gặp Arsenal".
- ❑ **Dữ liệu thô phức tạp:** Dữ liệu ban đầu chỉ là các con số thống kê (HomeTeam, AwayTeam, FTHG, FTAG), cần phải có thuật toán để chuyển hóa thành ngôn ngữ tự nhiên.

## 4. DỮ LIỆU VÀ TIỀN XỬ LÝ

### 4.1 Tập dữ liệu sử dụng

Nguồn dữ liệu được thu thập từ chuyên trang thống kê football-data.co.uk, bao gồm thông số các trận đấu của 5 giải VĐQG hàng đầu châu Âu mùa giải mới nhất.

### 4.2 Sinh dữ liệu tự động

Do mô hình cần học từ văn bản, em đã xây dựng script tự động quét qua các dòng dữ liệu thô và sinh ra tập `qa_train.csv` với cấu trúc:

| Question (Câu hỏi)                       | Answer (Câu trả lời)               | Topic (Chủ đề) |
|------------------------------------------|------------------------------------|----------------|
| Kết quả trận Chelsea vs Man City ngày... | Trận đấu kết thúc với tỷ số 1-1.   | Kết quả        |
| Đội nào giành chiến thắng trong trận...  | Man City đã xuất sắc đánh bại...   | Thắng thua     |
| Có tổng cộng bao nhiêu bàn thắng...      | Trận đấu có tổng cộng 2 bàn thắng. | Bàn thắng      |

### 4.3 Tiền xử lý dữ liệu

Sử dụng thư viện **NLTK** và biểu thức chính quy (Regex) để làm sạch văn bản (loại bỏ dấu câu, ký tự đặc biệt).

Đưa toàn bộ chữ về in thường (Lowercase).

Sử dụng **TF-IDF Vectorizer** để tính toán mức độ quan trọng của các từ khóa (như tên đội bóng), biến các câu văn thành vector toán học.

## 5. CÁC PHƯƠNG PHÁP THỰC NGHIỆM

Hệ thống sử dụng luồng xử lý kép (Dual-model pipeline) để đưa ra câu trả lời:

### 5.1 Multinomial Naive Bayes

**Mục đích:** Khi người dùng nhập câu hỏi, mô hình Naive Bayes sẽ dự đoán xem người dùng đang muốn hỏi về chủ đề gì (Topic: Kết quả, Bàn thắng, hay Thẻ phạt).

**Ưu điểm:** Tốc độ huấn luyện cực nhanh, hoạt động hiệu quả với dữ liệu văn bản dạng TF-IDF.

### 5.2 K-Nearest Neighbors – KNN

**Mục đích:** Sau khi xác định được chủ đề, thuật toán KNN (K=5) sẽ tính toán khoảng cách cosine giữa vector câu hỏi của người dùng và các vector câu hỏi trong cơ sở dữ liệu.

**Hoạt động:** Hệ thống sẽ trích xuất câu trả lời của câu hỏi có khoảng cách gần nhất (độ tương đồng cao nhất) để phản hồi lại cho người dùng.

## 6. TIẾN ĐỘ VÀ KẾT QUẢ ĐẠT ĐƯỢC

Tính đến thời điểm báo cáo giữa kỳ, dự án đã hoàn thiện các hạng mục sau:

- 1. Backend & AI:** Hoàn thiện script `generate_data.py` gộp dữ liệu 5 giải đấu. Chạy thành công `create.pkl.py` để trích xuất các mô hình `vectorizer.pkl`, `nb_model.pkl`, và `knn_model.pkl` vào hệ thống.
- 2. Frontend:** Tích hợp thành công giao diện "Modern Premium UI" mang phong cách Bóng đá (Tone màu xanh mặt cỏ, đen và vàng kim), tạo trải nghiệm mượt mà với Glassmorphism và hiệu ứng animations.
- 3. Tích hợp Server:** Ứng dụng đã chạy ổn định trên môi trường local thông qua file `chatbot_app.py`.

## 7. HƯỚNG PHÁT TRIỂN TRONG GIAI ĐOẠN TIẾP THEO

Để hoàn thiện đồ án vào cuối kỳ, hệ thống sẽ được nâng cấp các tính năng:

- **Đánh giá mô hình:** Xây dựng script để đo lường độ chính xác (Accuracy, F1-Score) của mô hình Naive Bayes và mức độ tin cậy (Confidence score) của KNN.
- **Mở rộng kho dữ liệu:** Cập nhật thêm thông tin về cầu thủ (Vua phá lưới, Thẻ phạt cá nhân) và bảng xếp hạng.
- **Tối ưu hóa Tiếng Việt:** Tích hợp các bộ tách từ chuyên dụng cho tiếng Việt (như `pyvi` hoặc `VnCoreNLP`) để mô hình bắt chính xác các cụm từ ghép như "Ngoại\_hạng\_Anh", "Việt\_vị".